

Relazione sul progetto: Profilazione degli stati con PCA e clustering

Dataset: Country-data.csv

Il progetto analizza 167 stati descritti da indicatori socio-economici, sanitari e demografici. L'obiettivo è individuare gruppi di stati simili tramite tecniche di apprendimento non supervisionato: standardizzazione, analisi delle componenti principali, K-Means e clustering basato su K-Neighbors.

voce	valore
osservazioni	167
feature numeriche	9
valori mancanti	0
k finale	3

Introduzione e obiettivo

Il clustering ricerca gruppi di oggetti tali che gli elementi dello stesso gruppo siano più simili tra loro e più differenti dagli elementi degli altri gruppi. Nel linguaggio usato a lezione, la procedura è non supervisionata: non sono disponibili etichette di classe, quindi la validazione è interna e si basa su coesione e separazione dei cluster.

La pipeline adottata segue le fasi richieste dalla consegna: caricamento dei dati, controllo delle feature, StandardScaler, analisi delle correlazioni, PCA, scelta del numero di gruppi con Elbow e Silhouette Score, K-Means e confronto con una tecnica basata sul grafo dei vicini più prossimi.

Feature del dataset

feature	descrizione
country	nome dello stato
child_mort	mortalità sotto i 5 anni per 1000 nati vivi
exports	esportazioni di beni e servizi in percentuale del PIL
health	spesa sanitaria totale in percentuale del PIL
imports	importazioni di beni e servizi in percentuale del PIL
income	reddito netto per persona
inflation	crescita annua del PIL totale
life_expec	aspettativa di vita media alla nascita
total_fer	numero medio di figli per donna
gdpp	PIL pro capite

Preprocessing dei dati


Le variabili hanno scale molto diverse: ad esempio income e gdp sono grandezze economiche con valori nell'ordine delle migliaia, mentre health, exports e imports sono percentuali. Per evitare che le variabili con scala più ampia dominino le distanze euclidee, è stato applicato StandardScaler. Ogni feature viene trasformata sottraendo la media e dividendo per la deviazione standard, ottenendo media circa zero e deviazione standard unitaria.

Statistiche descrittive principali

feature	mean	std	min	50%	max
child_mort	38.270	40.329	2.600	19.300	208.000
exports	41.109	27.412	0.109	35.000	200.000
health	6.816	2.747	1.810	6.320	17.900
imports	46.890	24.210	0.066	43.300	174.000
income	17144.689	19278.068	609.000	9960.000	125000.000
inflation	7.782	10.571	-4.210	5.390	104.000
life_expec	70.556	8.893	32.100	73.100	82.800
total_fer	2.948	1.514	1.150	2.410	7.490
gdp	12964.156	18328.705	231.000	4660.000	105000.000


Analisi esplorativa

La prima analisi grafica riguarda le distribuzioni delle variabili. Alcune feature economiche risultano molto asimmetriche: pochi paesi presentano reddito e PIL pro capite molto alti, mentre molti stati si concentrano su valori bassi o intermedi.



Correlazioni nello spazio delle feature

La matrice di correlazione mostra relazioni coerenti con l'interpretazione del problema: child_mort e total_fer tendono a muoversi insieme, mentre sono in relazione negativa con life_expec. Le variabili income e gdpp sono invece fortemente associate e rappresentano una dimensione economica comune.




PCA e selezione delle feature

La PCA trasforma il dataset in un nuovo sistema di assi ortogonali. Le componenti principali sono ordinate per varianza spiegata: PC1 è la direzione lungo cui i dati variano maggiormente, PC2 la seconda direzione ortogonale. La consegna richiede anche di valutare un sottoinsieme di feature; per questo è stato confrontato il dataset completo con un subset socio-economico/sanitario.


scenario	numero_feature	varianza_prime_2_PC	k_migliore_silhouette	silhouette_migliore
tutte_le_feature	9	0.631	3	0.442
subset_socio_sanitario	5	0.916	3	0.574

Il subset scelto è formato da child_mort, income, life_expec, total_fer, gdpp. Le prime due componenti spiegano il 91.6% della varianza, quindi il piano PCA conserva molta informazione utile per visualizzare e clusterizzare gli stati.

Scree Plot e Biplot




Nel biplot gli score rappresentano gli stati nel nuovo sistema di coordinate, mentre le frecce rappresentano i loading delle variabili originali. Vettori vicini indicano correlazione positiva, vettori opposti indicano correlazione negativa.



Scelta del numero di cluster


Il metodo Elbow osserva la riduzione del WCSS/inertia al crescere di k, mentre la silhouette media misura quanto ogni osservazione è coerente con il proprio cluster rispetto agli altri. Nel nostro caso il gomito automatico indica k=4, mentre la silhouette è massima per k=3. La scelta finale è k=3, perché fornisce la separazione media migliore nel piano delle prime due componenti principali.



k	inertia	silhouette
2	350.323	0.505
3	155.125	0.574
4	110.462	0.513
5	74.260	0.534
6	55.881	0.490
7	41.247	0.510
8	34.644	0.504
9	29.367	0.472
10	24.998	0.472


Clustering K-Means

K-Means è un metodo partizionale center-based: ogni cluster è rappresentato da un centroide e ogni punto viene assegnato al centroide più vicino. Applicato alle prime due componenti principali del subset selezionato, ottiene silhouette media pari a 0.574. Nel grafico sono mostrati anche i centri di massa dei cluster, come richiesto dalla consegna.



Profilazione dei cluster


Il profilo medio standardizzato permette di interpretare i gruppi. Valori positivi indicano feature sopra la media del dataset, valori negativi indicano feature sotto la media. In generale emergono un gruppo fragile, con mortalità infantile e fertilità alte, un gruppo intermedio e un gruppo più avanzato con income, gdpp e life_expec più elevati.



cluster	child_mort	income	life_expec	total_fer	gdpp	dimensione	nome_profilo
0	-0.816	1.596	1.074	-0.720	1.686	34	profilo avanzato
1	1.356	-0.699	-1.295	1.360	-0.608	47	profilo fragile
2	-0.418	-0.249	0.283	-0.459	-0.334	86	profilo intermedio

Clustering K-Neighbors

Poiché il dataset non contiene una variabile target, K-Neighbors è stato usato in forma non supervisionata: si costruisce un grafo di affinità collegando ogni stato ai suoi vicini più prossimi nel piano PCA e poi si applica SpectralClustering su tale grafo. La silhouette ottenuta è 0.570; l'Adjusted Rand Index tra K-Means e K-Neighbors è 0.909, quindi i due metodi sono confrontabili ma non identici.



Esempi di stati e conclusioni

Esempi di paesi vicini al centroide

Cluster	Paesi più centrali
Cluster 0	Ireland, Australia, Sweden, Canada, Netherlands, Finland, Austria
Cluster 1	Togo, Tanzania, Liberia, Benin, Gambia, Lesotho, Cameroon
Grenada, Ecuador, Cuba, St. Vincent and the Grenadines, Peru, Dominican Republic, Panama	

L'analisi conferma che la struttura principale del dataset è guidata da una contrapposizione tra indicatori di fragilità demografica/sanitaria e indicatori di sviluppo economico. La standardizzazione è necessaria per rendere confrontabili le variabili; la PCA consente di proiettare gli stati in uno spazio a bassa dimensione; Elbow e Silhouette supportano la scelta del numero di gruppi; K-Means fornisce una partizione compatta e interpretabile, mentre K-Neighbors evidenzia una struttura locale basata sulle relazioni di prossimità.

Librerie utilizzate

pandas per il caricamento e la gestione dei dati, numpy per il calcolo numerico, matplotlib per le visualizzazioni, scikit-learn per StandardScaler, PCA, KMeans, SpectralClustering, kneighbors_graph e metriche di validazione, reportlab per la generazione della relazione PDF.